

Épocas y series mínimas para estimar el beta óptimo

Cuánto se puede recortar el grid search de fuerza bruta sin perder precisión

Walter Quiñonez

Reporte generado con Claude Code · 8 de septiembre de 2026

El grid search de fuerza bruta (data_beta_grid_search_SP/) usa series=20, k_folds=5, epochs=100 por cada uno de los 40 betas de la grilla, en cada una de las 30 combinaciones INL×pulsos ya exploradas (≈12 millones de época-fold-serie, 34 GB en disco). Este reporte cuantifica cuánto de eso es necesario para identificar un beta óptimo igual de bueno, reutilizando los datos ya existentes (sin correr nada nuevo) y corroborando con un puñado de corridas nuevas mínimas. No se modificó Crossbar_train_experimento_beta_por_capa.py ni MemCrossbarClass_beta_por_capa.py.

Índice

1. El criterio correcto no es “¿coincide el beta?”, es “¿cuánto se pierde?”	1
2. Épocas mínimas (30 combos, datos ya existentes)	2
3. Series y folds mínimos (subsampling sobre datos ya existentes)	2
4. Corroboración con corridas nuevas (código copiado, semillas nuevas)	3
5. Recomendación final	4
6. Limitaciones	4

1. El criterio correcto no es “¿coincide el beta?”, es “¿cuánto se pierde?”

Cerca del óptimo, la curva accuracy-vs-beta es muy plana: varios betas vecinos dan una accuracy final indistinguible dentro del ruido estadístico. Pedir que el $\arg \max_{\beta}$ coincida exactamente con el de la corrida completa penaliza saltos sin ningún costo práctico (con ese criterio, la mediana de épocas necesarias sería 40, y el peor caso 100 – no se podría recortar nada).

En cambio, se define el *regret*: si la búsqueda de beta se cortara en la época e y me quedara con $\hat{\beta}(e) = \arg \max_{\beta} \overline{\text{acc}}(\beta, e)$, pero esa red se entrenara igual hasta la época 100, ¿cuánta accuracy final pierdo respecto del óptimo real?

$$\text{regret}(e) = \text{acc}_{\text{óptima}}(100) - \overline{\text{acc}}(\hat{\beta}(e), 100)$$

Éste es el criterio relevante para decidir cuántas épocas necesita la *búsqueda* de beta (no el entrenamiento final).

2. Épocas mínimas (30 combos, datos ya existentes)

Buscando la mínima época a partir de la cual $\text{regret}(e) < \text{tol}$ se sostiene hasta la época 100:

Tolerancia de regret	mediana	p90	p95	máx (peor de 30 combos)
2.0 pp	1	1	1	1
1.0 pp	1	1	1	8
0.5 pp	1	–	7.5	19
0.2 pp	1	–	20.6	38

Cuadro 1: Época mínima con regret sostenido por debajo de la tolerancia, sobre los 30 combos INL×pulsos ya explorados. El regret máximo observado en absoluto (cualquier época/combo) fue 1.48 pp.




Figura 1: Época mínima (criterio de regret <1pp) vs. INL nominal, por cantidad de pulsos.

Conclusión: con una tolerancia de 1 punto porcentual de accuracy final, **8 épocas alcanzan** en el peor de los 30 regímenes ya explorados (recomendación con margen: **epochs_min = 10**). Esto es consistente con que `search_best_beta()` (ya presente en el código, desactivado por defecto) entrena solo 1 época por candidato de beta.

3. Series y folds mínimos (subsampling sobre datos ya existentes)

Para cada combo, subsampleando sin reemplazo n series (de las 20 disponibles) y k folds (de los 5 disponibles), 300 repeticiones por punto, evaluando accuracy en la época 8 (el `epochs_min` de la

sección anterior):

n series (folds=5)	$P(\text{regret} < 1\text{pp})$ media	peor combo
1	95.8 %	43.3 %
5	98.9 %	82.0 %
8	99.7 %	93.3 %
12	99.9 %	98.0 %
16 – 20 (todas)	100.0 %	100.0 %

Cuadro 2: Confiabilidad de la elección de beta según cantidad de series usadas.

Variando $k_folds \in \{1, 2, 3, 5\}$ con series=20 fijo: $k_folds = 3$ ya da 100 % de confiabilidad en los 30 combos, igual que $k_folds = 5$.




Figura 2: Confiabilidad ($P(\text{regret} < 1\text{pp})$) vs. cantidad de series usadas, para los 30 combos (líneas finas) y su media/peor caso (líneas gruesas).

Conclusión: $\text{series_min} = 12$, $k_folds_min = 3$ dan $\geq 98\%$ de confiabilidad en el peor de los 30 regímenes ya explorados (100 % en promedio).

4. Corroboración con corridas nuevas (código copiado, semillas nuevas)

Para descartar que la recomendación sea un artefacto de reciclar los mismos datos, se corrieron 2 combos representativos (extremos de no linealidad: INL nominal 2×10^{-1} y 1×10^{-2}) con semillas de fold completamente nuevas y el protocolo reducido más agresivo considerado (**series=8**, **k_folds=3**, **epochs=8**, $\approx 400\times$ más barato que el original), usando una copia adaptada del script original (codigo_reducido/Crossbar_train_confirmatorio.py; el original no fue modificado) con chequeo de espacio en disco (≥ 50 GB libres) antes de cada serie.

Combo	β elegido (protoc. reducido)	β óptimo (ground truth)	acc. (gr. truth, $\hat{\beta}$, ep. 100)	acc. óptima (ground truth)	regret real
INL_2e-1_p_50	150	100	0.8434	0.8479	0.445 pp
INL_1e-2_p_100	300	350	0.9084	0.9091	0.071 pp

Cuadro 3: Resultado de la corroboración: beta elegido por el protocolo reducido más agresivo (**series=8**, **k_folds=3**, **epochs=8**, semillas de fold nuevas) evaluado contra el ground truth completo (20 series×5 folds×época 100). Ambos casos caen muy por debajo de la tolerancia de 1 pp fijada en las Secciones 2-3, con datos genuinamente nuevos (no reciclados de las 20 series ya usadas en el grid search original). Cada corrida tardó 55-57 minutos en CPU local.

5. Recomendación final

Parámetro	Original (grid search)	Recomendado	Reducción
epochs	100	10	10×
series	20	12	1.7×
k_folds	5	3	1.7×
Total (épocas×series×folds)	10 000	360	≈ 28 ×

Cuadro 4: Configuración recomendada para futuras búsquedas de beta óptimo en este proyecto (arquitectura SP, MNIST, ratio Gmax/Gmin=10).

Con $\geq 98\%$ de confiabilidad de identificar un beta a menos de 1 pp de accuracy del óptimo real, en cualquiera de los 30 regímenes de INL/pulsos ya explorados. Para una variante aún más agresiva (**series=8**, **k_folds=3**, **epochs=8**, $\approx 400\times$ más barata) la confiabilidad en el peor caso baja a $\sim 93\%$, corroborada puntualmente en la Sección 4.

6. Limitaciones

- Las Secciones 2-3 son un análisis *post-hoc* sobre los 30 combos ya explorados (arquitectura SP fija, MNIST, ratio Gmax/Gmin=10). No cubren variaciones de arquitectura (MLP), dataset (Fashion-MNIST) ni rango de conductancia distinto; si se exploran esos regímenes conviene repetir al menos la corroboración de la Sección 4 ahí.
- El regret se mide contra la propia accuracy a época 100 (no hay una verdad “más allá”); se asume que 100 épocas ya representa convergencia práctica en este problema.
- La Sección 4 corrobora con 2 combos y una corrida cada uno (no 30, no repetido), por costo de cómputo local; es una corroboración puntual, no exhaustiva.

Ver `documentacion_epochs_series_minimos.md` en esta misma carpeta para el desarrollo completo (definiciones exactas, código, tablas completas) verificable por un humano.