

La ecuación de β óptimo, revisada con 18 curvas (antes eran 6)

Walter Quiñonez

Reporte generado con Claude Code · 6 de septiembre de 2026

Este reporte repite el método de `reporte_formula_beta_optimo_propuesta.md (v1)` con la data nueva: ya no son 6 curvas (2 INL nominal $\times$ 3 pulsos), son 18 curvas (6 INL nominal $\times$ 3 pulsos), con INL nominal cubriendo casi 4.4 órdenes de magnitud ($2e-1 \dots 4.82e-6$) en vez de solo 2 valores. Además responde la pregunta que motivó este reporte: ¿las curvas de accuracy vs beta se aplanan a medida que el INL se achica, porque la curva P/D se vuelve más lineal? No se modificó ningún archivo existente del proyecto ni se corrió ningún entrenamiento nuevo.

Índice

1. La ecuación, ahora con $3\times$ más puntos y sin el problema de confusión de v1	1
2. “La curva P/D se vuelve más lineal cuando INL se achica”: ¿válido?	3
2.1. Que la curva P/D se acerca a la recta cuando INL baja — esto es la definición de INL, no un hallazgo	3
2.2. Que la curva de accuracy vs beta se aplanan cuando INL baja — esto SÍ es empírico, y la respuesta es “solo parcialmente, y con matices”	3
3. Conclusión	5
4. Registro de códigos usados	5

1. La ecuación, ahora con $3\times$ más puntos y sin el problema de confusión de v1

v1 advertía que su exponente de σ_W (-3.02) estaba determinado por un solo contraste entre 2 grupos de INL, no por una curva de potencia muestreada en muchos puntos. Con 6 valores de INL nominal en vez de 2, esa objeción ya no aplica: ahora hay grados de libertad reales para poner a prueba la forma de la ley.

La ecuación combinada:

$$\beta_{\text{óptimo}} \approx 1.34 \times 10^{-11} \cdot \sigma_W^{-3.05} \cdot \text{paso_medio}^{-0.61} \quad (1)$$

(exponentes: -3.047 para σ_W , -0.607 para paso medio; intercepto $\exp(-25.05) \approx 1.34 \times 10^{-11}$)

Modelo	R^2	n	gl residuales
solo σ_W	0.606	18	16
solo paso medio	0.333	18	16
combinado ($\sigma_W +$ paso medio)	0.938	18	15
directo ($\text{INL}_{\text{real}} +$ pulsos)	0.633	18	15




Figura 1: R^2 del ajuste log-log de $\beta_{\text{óptimo}}$ (18 puntos reales) usando cada modelo.

Esto es la confirmación que a v1 le faltaba: con 6 INL nominal en vez de 2, el exponente de σ_W sale -3.05 , prácticamente idéntico al -3.02 de v1 (ajustado con solo 2 grupos). El de paso medio sale -0.61 , muy cerca del -0.64 de v1. La ecuación combinada explica **93.8 %** de la varianza (log-log) de los 18 β óptimo reales, con errores de predicción entre $-27 %$ y $+26 %$ (tabla completa en `resultados_formula_propuesta_v2.csv`).




Figura 2: Ecuación combinada (1) vs. β óptimo empírico, 18 curvas, escala log-log.

También se probó un modelo más simple y barato (sin Monte Carlo): $\beta_{\text{óptimo}} \sim \text{INL}_{\text{real}}^b \cdot \text{pulsos}^d$. Da $R^2 = 0.633$ — mejor que σ_W sola pero bastante peor que la combinada. Confirma que σ_W (la distribución de pesos real, vía `G0_initialization`) captura algo que el INL nominal por sí solo no captura del todo.

Limitación que sigue en pie: $N = 784$ y el dataset (MNIST) siguen fijos en las 18 curvas, así que esos exponentes no son identificables con esta data (absorbidos en la constante). Y aunque ahora hay 6 valores de INL, los 4 nuevos ($1e-3$, $1e-4$, $1e-5$, $4.82e-6$) están muy cerca entre sí en el régimen “ya casi lineal” (Sección 2) — la verdadera diversidad geométrica de la curva P/D sigue concentrada en el contraste 2e-1 vs. el resto, igual que en v1.

2. “La curva P/D se vuelve más lineal cuando INL se achica”: ¿válido?

Sí, pero hay que separar dos afirmaciones distintas que se mezclan en la pregunta original.

2.1. Que la curva P/D se acerca a la recta cuando INL baja — esto es la definición de INL, no un hallazgo

`calcular_indice_nl()` (la función que define INL en todo el proyecto) es literalmente $(L - d)/d$: el exceso de longitud de la curva sobre la distancia recta, normalizado. $\text{INL} = 0$ significa curva perfectamente lineal **por construcción**. Decir “INL chico $\Rightarrow$ curva más lineal” es como decir “un termómetro que marca 0°C está más frío que uno que marca 100°C ”: cierto, pero no es una observación empírica sobre el sistema, es releer la definición de la métrica.

Dicho esto, vale la pena verlo graficado para calibrar cuánto cambia la forma, porque esa magnitud sí importa para la Sección 2.2:




Figura 3: Curva P/D normalizada, una por INL nominal ($p=100$).

El salto grande de curvatura ocurre entre $\text{INL} = 2e-1$ ($a = 11.8$, muy cóncava) e $\text{INL} = 1e-2$ ($a = 98.5$, moderada). De ahí para abajo ($1e-3$, $1e-4$, $1e-5$, $4.82e-6$ — cuatro órdenes de magnitud más de “achicar el INL”), las curvas son **visualmente indistinguibles entre sí y de la recta** a esta escala: la curva ya “saturó” hacia la forma lineal mucho antes de llegar a $\text{INL} = 1e-5$. Esto es la clave para entender la Sección 2.2.

2.2. Que la curva de accuracy vs beta se aplana cuando INL baja — esto SÍ es empírico, y la respuesta es “solo parcialmente, y con matices”

Se midieron dos descriptores de “qué tan picuda” es cada una de las 18 curvas accuracy-vs-beta reales:

- **ancho de meseta @99 %** (normalizado por $\beta_{\text{óptimo}}$): rango de β alrededor del pico donde $\text{accuracy} \geq 99\%$ del máximo, con interpolación lineal en los bordes.

- **curvatura local en el pico:** coeficiente cuadrático de una parábola ajustada a los puntos cercanos al máximo (más cerca de 0 = más plana).




Figura 4: Ancho de meseta y $|curvatura|$ en el pico, vs. INL real, para las 18 curvas.

Correlación (log-log) a lo largo de las 18 curvas:

Comparación	r (18 curvas)	r (15 curvas, sin INL=2e-1)
INL vs. ancho meseta @99 %/ $\beta_{\text{óptimo}}$	-0.41	-0.12
INL vs. $ curvatura $ en el pico	+0.55	+0.12

Conclusión honesta: la correlación completa ($r = 0.41\text{--}0.55$) sugiere que sí, en general, INL más chico $\Rightarrow$ curva más plana. Pero al sacar el único grupo con INL grande (2e-1) de la comparación, la correlación **se cae a casi cero** ($r = 0.12$) entre los 5 grupos restantes (1e-2 hasta 4.82e-6, que ya cubren 4 órdenes de magnitud). Es decir: **el “aplanamiento” no es una tendencia continua que sigue creciendo a medida que INL se achica más y más** — es, otra vez, un efecto de **un solo contraste** (INL muy alto = 2e-1, curva P/D muy cóncava, óptimo de β muy picudo) **vs. todo lo demás** (INL moderado a chico, curva P/D ya casi lineal, óptimo de β con meseta ancha). Una vez que la curva P/D ya está “casi lineal” (que pasa a partir de $\text{INL} \approx 1\text{e-}2$ en este sistema, Sección 2.1), seguir bajando el INL no aplanan más el óptimo de accuracy — coincide exactamente con que la propia curva P/D tampoco se pone visiblemente “más recta” a partir de ahí.

Esto es coherente con lo que ya había encontrado v1 sobre σ_W : con INL nominal solo en 2 valores, cualquier tendencia “entre grupos” corre el riesgo de ser, en realidad, un efecto de un único contraste. Con 6 valores de INL ahora se puede ver eso explícitamente en vez de solo sospecharlo.

3. Conclusión

1. **La ecuación combinada de v1 se sostiene** con datos $3\times$ más ricos y sin el problema de confusión que v1 mismo señalaba: Ec. 1, $R^2 = 0.938$ sobre 18 curvas reales (antes: $R^2 = 0.947$ sobre 6, con solo 2 valores de INL). Los exponentes casi no se movieron (-3.05 vs. -3.02 ; -0.61 vs. -0.64) — buena señal de que no era un ajuste espurio de v1.

2. “**INL chico $\Rightarrow$ curva P/D más lineal**” es verdadero por definición de INL, no un hallazgo — pero graficarlo muestra que, en este sistema, la curva ya está casi saturada hacia la recta a partir de $\text{INL} \approx 1\text{e-}2$; seguir bajando el INL otras 3-4 décadas cambia poco su forma visible.
3. “**La curva de accuracy se aplanar cuando INL se achica**” es cierta solo como contraste entre el régimen muy no-lineal ($\text{INL} \sim 0.2$) y todo lo demás — no como una tendencia continua dentro del régimen ya casi lineal ($\text{INL} \leq 1\text{e-}2$). Los nuevos datos de $\text{INL} = 5\text{e-}2 \dots 5\text{e-}5$ (corriendo en el cluster al momento de este reporte) van a ayudar a rellenar justo la zona de transición (entre $2\text{e-}1$ y $1\text{e-}2$) donde, según este análisis, está ocurriendo casi todo el efecto — y a confirmar si por debajo de $1\text{e-}2$ el aplanamiento sigue plano (como sugieren estos 18 puntos) o si con más resolución aparece algo de tendencia que acá no se alcanza a ver.

4. Registro de códigos usados

- `estimar_beta_optimo_propuesta_v2.py` — Único script nuevo. Repite el Monte Carlo de v1 sobre las 18 curvas, agrega el análisis de planitud (ancho @99 % y curvatura), y las 4 regresiones log-log.
- `estimar_beta_optimo_propuesta.py` (v1) — método original (σ_W , paso medio, Monte Carlo de corriente corregido); no modificado.
- `MemCrossbarClass_beta_por_capa.py` $\rightarrow$ `generar_curvas_pot_dep()`, `G0_initialization()` — usadas sin modificar, tal como en la red real.
- `data_beta_grid_search_SP/plot_accuracy_vs_beta_por_INL.py` $\rightarrow$ `cargar_curva()` — reutilizada sin modificar para obtener la curva completa (beta, accuracy) de cada carpeta y medir su planitud.
- `data_beta_grid_search_SP/beta_grid_search_SP_INL_*/config*.json` — parámetros reales de cada una de las 18 curvas P/D.
- `data_beta_grid_search_SP/resumen_por_INL/resumen_optimos.csv` — los 18 β óptimo empíricos usados para el ajuste.
- `X_train_mnist.npy` — píxeles reales muestreados (respetando frecuencia) en el Monte Carlo de corriente.

Archivos generados por este reporte (todos en `formula_beta_optimo_propuesta/`):
`estimar_beta_optimo_propuesta_v2.py`, `resultados_formula_propuesta_v2.csv`,
`coeficientes_regresion_v2.csv`, `curvas_PD_normalizadas_vs_INL_v2.png`,
`planitud_vs_INL_v2.png`, `beta_pred_combinada_vs_empirico_v2.png`, `comparacion_R2_v2.png`,
`reporte_formula_beta_optimo_propuesta_v2.tex` y este PDF.