

Distribución de logits y softmax vs β

INL=2e-1 vs INL=1e-2, comparando $p = 50/100/200$

Walter Quiñonez

Reporte generado con Claude Code · 7 de septiembre de 2026
(ampliado el mismo día con la Sección 7: extensión a INL=1e-2)

Se reconstruyen (sin reentrenar nada) los logits $\beta \cdot I$ de validación de las 40 corridas de β de `data_beta_grid_search_SP/`, para INL=2e-1 con $p = 50, 100, 200$ pulsos, y se analiza la distribución softmax resultante para responder: ¿tiene algo particular el β óptimo empírico, y es común entre distintos p ?

Índice

1. Método	1
2. Resultado principal: lo que NO es común entre p	1
3. Ejemplo detallado: $p = 50$ (la curva con el acantilado más marcado)	2
4. Lo que SÍ parece común: el desvío estándar de los logits en el óptimo	2
5. Interpretación	3
6. Próximos pasos (planteados en la primera versión de este reporte)	4
7. Archivos generados (Secciones 1–6, sobre INL=2e-1)	4
8. Ampliación: ¿es esto propio de INL=2e-1, o aparece también en curvas casi lineales?	5
8.1. Respuesta (a): el acantilado SÍ es propio de INL grande (muy no lineal)	5
8.2. Respuesta (b): el <code>logit_std</code> en el óptimo NO es universal —depende del INL	6
8.3. Interpretación revisada	7
8.4. Próximos pasos (actualizado)	8
9. Archivos generados (todo el reporte, actualizado)	8

1. Método

Reconstrucción exacta y determinista: `forward()` de `MemDNN` no tiene ruido ni aleatoriedad en esta grilla, así que logits = $\beta \cdot (X @ (G^+ - G^-))$ se puede recalculare sobre el set de validación a partir del `G_history*.npz` ya guardado, sin reentrenar. Se usa la serie 0 y la última época guardada

(100, modelo convergido); los 5 folds de esa serie no se solapan y cubren el dataset completo (60000 imágenes de MNIST), y usan la *misma* partición en las 40 corridas de β de cada grilla, así que son directamente comparables. **Sanity check:** la accuracy reconstruida coincide con la accuracy ya guardada durante el entrenamiento real, con diferencia máxima de $3,3 \times 10^{-5}$ ($p=50$), $1,7 \times 10^{-5}$ ($p=100$) y $1,7 \times 10^{-5}$ ($p=200$) sobre las 40 corridas de cada grilla.

β óptimo empírico de cada curva (`resumen_por_INL/resumen_optimos.csv`): $p=50 \rightarrow \beta^*=100$ (84.79 %), $p=100 \rightarrow \beta^*=100$ (86.57 %), $p=200 \rightarrow \beta^*=200$ (88.96 %).

Scripts: `analisis_distribucion_softmax_INL_2e-1_p_{50,100,200}/analizar_distribucion_softmax.py` (idéntico método en los tres) y `comparar_p.py` (esta carpeta, solo lee los tres `resumen_por_beta.csv` ya generados).

2. Resultado principal: lo que NO es común entre p




Figura 1: Accuracy reconstruida vs β , las tres curvas superpuestas. Las líneas punteadas verticales marcan el β óptimo de cada una.

Las tres curvas suben de forma casi idéntica hasta su β óptimo (arrancan en ~ 65 % en $\beta=1$ y llegan a 84–89 % en $\beta \approx 100$ –200). La diferencia grande aparece **después** del óptimo:

- $p = 50$: colapso abrupto tipo acantilado. Entre $\beta=200$ y $\beta=300$ la accuracy cae de 81.5 % a 38.9 %, y después queda oscilando sin tendencia entre 27 % y 39 % hasta $\beta=1950$ — un régimen básicamente roto.
- $p = 100$: caída más gradual (81.9 % $\rightarrow$ 71.5 % $\rightarrow$ meseta ruidosa de 50–58 % desde $\beta \approx 900$) — se degrada mucho, pero sin el escalón brusco de $p = 50$.
- $p = 200$: caída suave y casi monótona, de 88.6 % en $\beta=200$ a ~ 60 % en $\beta=1950$, sin ningún salto abrupto — la más robusta a pasarse de β .

O sea: a mayor cantidad de pulsos (curva P/D más fina), la red se vuelve más tolerante a un β excesivo. El mismo patrón aparece en la calibración: el ECE de $p=50$ da un salto brusco justo después del acantilado ($0.044 \rightarrow 0.258$ entre $\beta=250$ y 300), mientras que en $p=100$ y $p=200$ el ECE post-óptimo sube de forma progresiva, sin escalón.

3. Ejemplo detallado: $p = 50$ (la curva con el acantilado más marcado)




Figura 2: Distribución de confianza softmax (max-prob) por β , $p = 50$. En β chico el softmax es casi uniforme (masa pegada a 0.1); en el óptimo ($\beta=100$) ya se separó del uniforme pero sin saturar; en β grande se concentra fuertemente cerca de 1 pese a que la accuracy real ya colapsó.

Las figuras equivalentes para $p = 100$ y $p = 200$ (mismo patrón cualitativo, degradación post-óptimo más suave) están en sus respectivas carpetas (`analisis_distribucion_softmax_INL_2e-1_p_100/` y `..._p_200/`).

4. Lo que SÍ parece común: el desvío estándar de los logits en el óptimo

p	β^*	accuracy	conf. media	entropía	ECE	brecha conf.	logit std	frac. saturada
50	100	0.8446	0.617	1.213	0.227	0.269	1.78	0.000
100	100	0.8665	0.634	1.170	0.232	0.282	1.82	0.000
200	200	0.8858	0.744	0.821	0.142	0.307	2.74	0.001

Cuadro 1: Métricas en el β óptimo de cada curva. Tabla completa: `comparacion_en_beta_optimo.csv`.




Figura 3: Diagramas de *reliability* por β , $p = 50$. β chico: subconfiado (barras sobre la diagonal). β óptimo: el más cercano a la diagonal en confianzas altas. β grande: sobreconfiado (barras muy por debajo de la diagonal).

$p=50$ y $p=100$ tienen el *mismo* β óptimo (100) y dan un `logit_std` casi idéntico (1.78 vs 1.82 — 2 % de diferencia) pese a tener curvas P/D de distinta resolución. $p=200$ tiene β óptimo distinto (200, el doble) y da `logit_std`=2.74 — más alto, pero del mismo orden de magnitud, lejos de los valores de saturación (`logit_std` $\gtrsim 10$) que aparecen en las tres curvas bien pasado el óptimo. En las tres, el tramo “sano” corresponde a `logit_std` en el rango aproximado **1.8–3.6**.

Esto es coherente con la lógica de $\beta_{\text{óptimo}} \sim \kappa/\sigma_I$ de `validacion_formula_beta_optimo`/: si $\kappa \sim O(1)$ es aproximadamente independiente de p , el β que hace que $\sigma_I \cdot \beta$ (el `logit_std` de la tabla) caiga en ese rango angosto es, precisamente, el β óptimo — con la salvedad de que en los datos reales esa cantidad no es una constante perfecta sino que crece levemente con p (1.78 $\rightarrow$ 1.82 $\rightarrow$ 2.74).

También son comunes, cualitativamente: la forma en U del ECE vs β (mínimo un poco *después* del β óptimo, no exactamente en él), y que la separación de confianza correctos/incorrectos alcance su pico muy cerca del β óptimo en las tres curvas.

5. Interpretación

Para $\text{INL}=2\text{e-}1$ (curva P/D muy no lineal), el β óptimo de cada p cae siempre en la zona de la grilla donde (1) el entrenamiento todavía converge de forma estable —cuya severidad de ruptura posterior SÍ depende mucho de p — y (2) el desvío estándar de los logits está en un rango angosto de orden 1–3, prácticamente el mismo entre $p=50$ y $p=100$ y solo moderadamente más alto en $p=200$. El “qué tiene de particular” no está en una propiedad exacta del softmax en sí (ni ECE, ni confianza, ni entropía tocan su propio óptimo justo en β^*), sino en que β^* es el β más grande que todavía mantiene la dispersión de los logits dentro de ese rango angosto — más allá de él, la dinámica de entrenamiento (β multiplica también el gradiente) se degrada, a velocidad muy distinta según p .




Figura 4: Desvío estándar de los logits crudos ($\beta \cdot I$) vs β , escala log en y . Las estrellas marcan el β óptimo de cada curva; la banda gris marca el rango de `logit_std` en esos tres óptimos (1.8–2.7).

6. Próximos pasos (planteados en la primera versión de este reporte)

Falta repetir este análisis para los INL más chicos (curvas P/D casi lineales, donde `accuracy_vs_beta_INL_*.png` ya sugiere picos mucho más suaves, sin acantilado) para ver si el rango de `logit_std` en el óptimo se mantiene parecido, y si el “acantilado de estabilidad” es propio de curvas P/D muy no lineales (INL grande) o aparece también, más atenuado, en curvas casi lineales. **Esto es exactamente lo que se responde en la Sección 8**, repitiendo el análisis para $\text{INL}=1\text{e-}2$ (curva casi lineal) con los mismos $p = 50/100/200$.

7. Archivos generados (Secciones 1–6, sobre $\text{INL}=2\text{e-}1$)

- `comparar_p.py`, `comparacion_en_beta_optimo.csv`, `accuracy_vs_beta_comparado.png`, `logit_std_vs_beta_comparado.png` (esta carpeta).
- Por cada p (`analisis_distribucion_softmax_INL_2e-1_p_{50,100,200}/`): `analizar_distribucion_softmax.py`, `resumen_por_beta.csv`, `distribuciones_representativas.npz`, y 6 figuras cada una (accuracy, confianza/entropía, calibración, histogramas de confianza y de logits, diagramas de reliability).

8. Ampliación: ¿es esto propio de $\text{INL}=2\text{e-}1$, o aparece también en curvas casi lineales?

Se repitió exactamente el mismo análisis (mismo método, misma serie 0, misma última época) para $\text{INL}=1\text{e-}2$ —una curva P/D casi lineal, dos órdenes de magnitud menos no lineal que $2\text{e-}1$ — con

los mismos $p = 50/100/200$. Sanity check igual de ajustado: diferencia máxima $1,7 \times 10^{-5}$ ($p=50$), $1,7 \times 10^{-5}$ ($p=100$) y $9,4 \times 10^{-8}$ ($p=200$) entre accuracy reconstruida y guardada. β óptimo empírico: $p=50 \rightarrow \beta^*=250$ (89.47 %), $p=100 \rightarrow \beta^*=350$ (90.91 %), $p=200 \rightarrow \beta^*=750$ (91.63 %).

Scripts: `analisis_distribucion_softmax_INL_1e-2_p_{50,100,200}/analizar_distribucion_softmax.py` y `comparar_INL.py` (esta sección, solo lee los 6 `resumen_por_beta.csv` ya generados).

8.1. Respuesta (a): el acantilado SÍ es propio de INL grande (muy no lineal)




Figura 5: Accuracy vs β : INL=2e-1 (líneas sólidas) vs INL=1e-2 (líneas punteadas), para $p = 50, 100, 200$.

La diferencia es enorme y confirma la sospecha de la Sección 8:

- INL=1e-2, $p = 50$: baja de forma *suave*, sin ningún escalón —de 89.3 % en $\beta^*=250$ a ~ 55 % recién en $\beta=1950$ — mucho más gradual que su contraparte INL=2e-1, $p = 50$, que colapsaba a 30–39 % ya en $\beta=300$.
- INL=1e-2, $p = 100$: se mantiene por encima de 90 % hasta $\beta \approx 650$, y baja gradualmente hasta ~ 70 % en $\beta=1950$ —sin ningún salto abrupto.
- INL=1e-2, $p = 200$: prácticamente **una meseta**. Se mantiene entre 90.3 % y 91.7 % desde $\beta=200$ hasta $\beta \approx 1400$, y termina en 87.8 % en $\beta=1950$ —la accuracy casi no se resiente en todo el rango de la grilla. Es, con diferencia, la curva más robusta de las 6 analizadas hasta ahora.

O sea: el “acantilado de estabilidad” no es un fenómeno general del sistema —es específico de curvas P/D muy no lineales (INL grande). Con INL chico (curva casi lineal), aumentar β mucho más allá del óptimo degrada la accuracy de forma suave y acotada, en vez de romper el entrenamiento.

8.2. Respuesta (b): el `logit_std` en el óptimo NO es universal —depende del INL




Figura 6: Desvío estándar de los logits crudos vs β (escala log), INL=2e-1 (sólidas) vs INL=1e-2 (punteadas). Las bandas sombreadas marcan el rango de `logit_std` en los 3 β óptimos de cada INL: no se tocan entre sí.

INL	p	β^*	accuracy	ECE	logit std	frac. saturada
2e-1	50	100	0.8446	0.227	1.78	0.000
2e-1	100	100	0.8665	0.232	1.82	0.000
2e-1	200	200	0.8858	0.142	2.74	0.001
1e-2	50	250	0.8932	0.085	3.49	0.014
1e-2	100	350	0.9096	0.059	4.28	0.032
1e-2	200	750	0.9166	0.031	6.37	0.078

Cuadro 2: Métricas en el β óptimo, INL x p . Tabla completa: `comparacion_en_beta_optimo_INL_y_p.csv`.

La hipótesis de la Sección 4 (banda universal `logit_std` $\approx$ 1,8–2,7) **no se sostiene entre INL distintos**: para INL=1e-2 el `logit_std` en el óptimo es 2–3 veces más alto (3.5–6.4) que para INL=2e-1 (1.8–2.7), y las dos bandas ni siquiera se tocan en la figura de arriba. Lo que sí se sostiene, y se refuerza con este segundo INL, es la parte más modesta de la hipótesis: **dentro de un mismo INL, el `logit_std` en el β óptimo queda en un rango angosto y crece solo levemente con p** (INL=2e-1: 1,78 $\rightarrow$ 1,82 $\rightarrow$ 2,74; INL=1e-2: 3,49 $\rightarrow$ 4,28 $\rightarrow$ 6,37 —mismo orden de crecimiento relativo con p en ambos casos, $\times$ 1,5–1,8 de $p=50$ a $p=200$).

También es consistente entre ambos INL que la fracción de softmax saturado en el propio β óptimo, aunque nunca despreciable para INL=1e-2 (1.4–7.8 %), se mantiene muy por debajo de los valores

>15–20 % que aparecen bien pasado el óptimo en ambas curvas.

8.3. Interpretación revisada

El resultado de la Sección 4 (β óptimo $\approx$ el β más grande que mantiene `logit_std` en 1.8–2.7) era, en realidad, una propiedad de $\text{INL}=2\text{e-}1$ específicamente, no una constante universal. La versión corregida:

- Dentro de una misma curva P/D (mismo INL), el `logit_std` óptimo es aproximadamente estable entre distintos p —la fórmula $\beta_{\text{óptimo}} \sim \kappa/\sigma_I$ con κ fijo parece describir razonablemente bien la variación *con p , a INL fijo*.
- Pero κ (o el `logit_std` óptimo efectivo) **sí depende del INL** : una curva P/D más lineal (INL chico) tolera un `logit_std` óptimo más alto que una muy no lineal (INL grande). Tiene sentido cualitativamente: con INL chico los pesos $G^+ - G^-$ están más concentrados/uniformes, así que la suma $I = \sum W_{ij}V_j$ es una variable más “bien portada” (más cerca del régimen gaussiano ideal de CLT que asume la fórmula), y tolera un β mayor antes de que la dinámica de entrenamiento se degrade.
- La severidad de la degradación post-óptimo (el acantilado) también depende fuertemente del INL : brusca y catastrófica en $\text{INL}=2\text{e-}1$, ausente o casi ausente en $\text{INL}=1\text{e-}2$.

8.4. Próximos pasos (actualizado)

- Confirmar la tendencia con un tercer punto de INL (por ejemplo $1\text{e-}4$ o $1\text{e-}5$, curvas P/D aún más lineales, ya con data disponible en `data_beta_grid_search_SP/`) para ver si el `logit_std` óptimo sigue subiendo al bajar el INL , y si se puede ajustar una relación funcional simple `logit_std_óptimo(INL)`.
- Extender la comparación de “severidad del acantilado” a los INL de la zona de transición ($7\text{e-}2$, $1\text{e-}1$, $1.3\text{e-}1$, $1.6\text{e-}1$, ver `train_job_INL_7e-2_p_50.sh` y afines —datos aún no generados/bajados) para ver en qué punto exacto del rango de INL aparece el acantilado.

9. Archivos generados (todo el reporte, actualizado)

- Secciones 1–6 (solo $\text{INL}=2\text{e-}1$): ver Sección 6.
- Sección 8 ($\text{INL}=1\text{e-}2$): carpetas `analisis_distribucion_softmax_INL_1e-2_p_{50,100,200}/` (mismo contenido que sus análogas de $\text{INL}=2\text{e-}1$), y en esta carpeta: `comparar_INL.py`, `comparacion_en_beta_optimo_INL_y_p.csv`, `accuracy_vs_beta_comparado_INL_y_p.png`, `logit_std_vs_beta_comparado_INL_y_p.png`.
- `reporte_distribucion_softmax_INL_2e-1.md` — versión Markdown de este mismo reporte (Secciones 1–8).